

ÍNDICE GENERAL

1	Introducción	1
1.1.	Procesamiento digital de imágenes	1
1.2.	Procesamiento digital de imágenes: fundamentos y aplicaciones con GNU Octave y OpenCV	1
2	Planteamiento del problema	3
2.1.	Objetivo general	4
2.2.	Objetivo específico	4
2.3.	Alcance	4
2.4.	Justificación	4
2.5.	Especificaciones técnicas	4
2.6.	Metodología	4
2.6.1.	Modelo de color HSV	5
2.6.2.	RoCoLe: A robusta coffee leaf images dataset for evaluation of machine learning based methods in plant diseases recognition	5
3	Procedimiento	7
3.1.	Lectura del dataset	7
3.1.1.	La clase CoffeeLeaf	8
3.2.	Procesado de la imagen	9
3.2.1.	Conversión de BGR a RGB	10
3.2.2.	Creación de las regiones de interés	10
3.2.3.	Creación de la máscara	13
3.2.4.	Enmascaramiento de las regiones de interés	14

3.2.5.	Histograma de la región de interés	15
3.2.6.	Segmentación de la imagen	16
3.2.7.	Clasificación de la hoja	17
3.3.	Presentación de los datos	18
3.3.1.	Resumen	19
3.3.2.	Imagen original	19
3.3.3.	Máscara	19
3.3.4.	Regiones de interés	20
3.3.5.	Imagen segmentada	20
3.3.6.	Histograma	20
4	Resultados	23
4.1.	Segmentación Hue en 40 y 120	23
4.2.	Segmentación Hue en 40 y 80	25
4.3.	Segmentación Hue en 30 y 120	27
4.4.	Segmentación Hue en 30 y 100	28
4.5.	Segmentación Hue en 30 y 80	30
4.6.	Segmentación Hue en 28 y 120	32
4.7.	Segmentación Hue en 25 y 120	33
5	Conclusiones	37
5.1.	Conclusiones específicas	37
5.1.1.	Unicidad de la solución	37
5.1.2.	Inconsistencias en el dataset	38
5.2.	Casos especiales	38
5.2.1.	Iluminación excesiva	38
5.2.2.	Iluminación artificial o no contemplada	40
5.2.3.	Envés de la hoja	41
5.3.	Mejoras y trabajo a futuro	42
5.3.1.	Detección de objetos	42
5.3.2.	Análisis en RGB	44
5.3.3.	Optimización de los umbrales de segmentación	45
5.3.4.	Redes neuronales artificiales	45
5.4.	Conclusiones generales	45
	Referencias	45

ÍNDICE DE CÓDIGOS

1.	Cargar las anotaciones del dataset	7
2.	La clase CoffeeLeaf	8
3.	Lista de objetos CoffeLeaf	9
4.	Función process del la clase CoffeeLeaf	9
5.	Iniciar procesamiento de las imágenes	10
6.	Convertir imagen BGR a RGB	10
7.	Puntos (x, y) del contorno de la hoja de café	11
8.	Crear regiones de interés	12
9.	Crear máscara	14
10.	Enmascarar las regiones de interés	14
11.	Cálcular histograma de la región de interés	16
12.	Segmentar la región de interés	17
13.	Clasificar hoja de café	18
14.	Describir objeto CoffeeLeaf	18
15.	Mostrar resumen de la clasificación	19
16.	Mostrar imagen original	19
17.	Mostrar máscara	19
18.	Mostrar regiones de interés	20
19.	Mostrar segmentación de la imagen	20
20.	Mostrar histograma de la región de interés	21

ÍNDICE DE FIGURAS

2.1. Modelo de color HSV	5
3.1. Imagen original en RGB	10
3.2. Polígono que delimita el contorno de la hoja	11
3.3. Cuadro que aisla a la hoja de café	12
3.4. Región de interés en RGB	13
3.5. Región de interés en HSV	13
3.6. Máscara	14
3.7. Región de interés RGB enmascarada	15
3.8. Región de interés Hue enmascarada	15
3.9. Histograma de la región de interés	16
3.10. Imagen segmentada	17
4.1. Eficiencia detectando el estado con Hue 40-120	24
4.2. Eficiencia detectando la categoría con Hue 40-120	24
4.3. Eficiencia por categoría con Hue 40-120	25
4.4. Eficiencia detectando el estado con Hue 40-80	25
4.5. Eficiencia detectando la categoría con Hue 40-80	26
4.6. Eficiencia por categoría con Hue 40-80	26
4.7. Eficiencia detectando el estado con Hue 30-120	27
4.8. Eficiencia detectando la categoría con Hue 30-120	27
4.9. Eficiencia por categoría con Hue 30-120	28
4.10. Eficiencia detectando el estado con Hue 30-100	29
4.11. Eficiencia detectando la categoría con Hue 30-100	29
4.12. Eficiencia por categoría con Hue 30-100	30
4.13. Eficiencia detectando el estado con Hue 30-80	30

4.14. Eficiencia detectando la categoría con Hue 30-80	31
4.15. Eficiencia por categoría con Hue 30-80	31
4.16. Eficiencia detectando el estado con Hue 28-120	32
4.17. Eficiencia detectando la categoría con Hue 28-120	32
4.18. Eficiencia por categoría con Hue 28-120	33
4.19. Eficiencia detectando el estado con Hue 25-120	34
4.20. Eficiencia detectando la categoría con Hue 25-120	34
4.21. Eficiencia por categoría con Hue 25-120	35
5.1. Inconsistencias en el dataset	38
5.2. Iluminación excesiva en una hoja	39
5.3. Matices falsos por iluminación excesiva	39
5.4. Segmentación de una hoja con iluminación excesiva	39
5.5. Hoja con iluminación no contemplada	40
5.6. Despliegue contraintuitivo de una imagen	40
5.7. Histograma de una imagen con despliegue contraintuitivo	41
5.8. Envés de una hoja saludable	41
5.9. Canal Hue del envés de una hoja saludable	42
5.10. Segmentación del envés de una hoja saludable	42
5.11. Contorno impreciso de una hoja saludable	43
5.12. Matices no deseados en un contorno impreciso	43
5.13. Introducción de zonas afectadas debido a un contorno impreciso	43
5.14. Hoja de café con afectación severa en zona reducida	44
5.15. Canal Hue de afectación severa en zona reducida	44
5.16. Área afectada de una hoja con afectación severa en zona reducida	45

ÍNDICE DE TABLAS

2.1. Niveles de afectación por roya	6
3.1. Anotaciones del dataset	8
4.1. Eficiencias generales con Hue 40-120	23
4.2. Eficiencia por categoría con Hue 40-120	24
4.3. Eficiencias generales con Hue 40-80	25
4.4. Eficiencia por categoría con Hue 40-80	26
4.5. Eficiencias generales con Hue 30-120	27
4.6. Eficiencia por categoría con Hue 30-120	28
4.7. Eficiencias generales con Hue 30-100	28
4.8. Eficiencia por categoría con Hue 30-100	29
4.9. Eficiencias generales con Hue 30-80	30
4.10. Eficiencia por categoría con Hue 30-80	31
4.11. Eficiencias generales con Hue 28-120	32
4.12. Eficiencia por categoría con Hue 28-120	33
4.13. Eficiencias generales con Hue 25-120	33
4.14. Eficiencia por categoría con Hue 25-120	34
5.1. Umbrales de segmentación recomendados	38



1

INTRODUCCIÓN

1.1. Procesamiento digital de imágenes

1.2. Procesamiento digital de imágenes: fundamentos y aplicaciones con GNU Octave y OpenCV

Durante el seminario *Procesamiento Digital de Imágenes: Fundamentos y Aplicaciones con GNU Octave y OpenCV* llevado a cabo en los meses de junio a agosto de 2025 e impartido por el PhD. Luis Escalante Zárte se revisaron varios temas principales acerca del procesamiento digital de imágenes.



2

PLANTEAMIENTO DEL PROBLEMA

El café es un producto altamente consumido en el mundo y es una de las bebidas más populares y preferidas en la sociedad. La producción de café representa un sustento económico para muchas familias en México y más precisamente en Chiapas que es uno de los principales estados exportadores de este grano.

El precio del café tuvo un incremento en el último año, sin embargo, las plagas representan un riesgo para su producción. Algunas plagas como la roya, la araña roja o la broca, pueden causar pérdidas severas tanto económicas como de materia prima que bien podrían minimizarse o incluso prevenirse mediante un monitoreo adecuado y regular de la plantación evitando medidas drásticas correctivas como la aplicación de químicos.

El monitoreo de los cultivos de café generalmente requiere de capacitación o asesoría técnica especializada que muchas veces es cara o inaccesible. El proyecto *Clasificación de hojas de café infectadas por roya usando segmentación por matices en el canal Hue* busca ofrecer una alternativa para quienes apenas ingresan en el mundo del café o bien si no se cuenta con los recursos de inversión suficientes.



2.1. Objetivo general

Demostrar las habilidades adquiridas durante el seminario *Procesamiento Digital de Imágenes: Fundamentos y Aplicaciones con GNU Octave y Open CV* aplicando los principios y técnicas básicas de manera práctica a un proyecto en particular.

2.2. Objetivo específico

Crear un algoritmo que clasifique hojas de café como sanas o infectadas por roya y su nivel de afectación, y evaluar su eficiencia comparando los resultados obtenidos con los proporcionados en el conjunto de datos.

2.3. Alcance

A pesar de que el conjunto de datos de prueba contiene seis clasificaciones para las hojas, el algoritmo desarrollado sólo incluirá la clasificación sana y los cuatro niveles de afectación por roya, excluyendo la clasificación *araña roja* debido a las restricciones en el tiempo del proyecto.

2.4. Justificación

El algoritmo y las técnicas utilizadas pueden aplicarse de manera directa en el mundo real dentro del área de la agricultura y/o agronomía, e idealmente puede servir como base para desarrollar procesos automatizados para el control de calidad en el ámbito del café y control de plagas.

2.5. Especificaciones técnicas

Se utilizará *Python* como lenguaje de programación para la implementación del algoritmo debido a su facilidad de uso y al amplio número de bibliotecas disponibles para el procesamiento de imágenes tales como *OpenCV*. Así mismo, se utilizará una libreta de *Jupyter* para la ejecución del algoritmo debido a su flexibilidad para ejecutar trozos de código de manera interactiva.

2.6. Metodología

El proceso comienza con la adquisición de las imágenes de las hojas de café, las cuales se transformarán del modelo RGB (Red, Green, Blue) al HSV (Hue, Saturation, Value) para poder aislar el canal Hue. Aplicando diferentes umbrales para los matices, segmentaremos la región de interés en busca de presencia de roya. Usando la imagen segmentada clasificaremos la severidad de la afectación a través de una operación entre el área de la imagen segmentada y una máscara que represente el área de la hoja. Finalmente revisaremos la eficiencia del algoritmo comparando nuestros resultados con las clasificaciones hechas por expertos.



2.6.1. Modelo de color HSV

El modelo de color HSV (Hue, Saturation, Value - Matiz, Saturación, Valor), también conocido como HSB (Hue, Saturation, Brightness - Matiz, Saturación, Brillo) es una representación no-lineal de los colores RGB (Red, Green, Blue - Rojo, Verde, Azul) que ofrece una representación más intuitiva ya que se asemeja a la forma en la que el ojo humano percibe el color.




Figura 2.1: Modelo de color HSV

Una de sus principales ventajas en el ámbito del procesamiento digital de imágenes es que facilita la segmentación de objetos coloridos. Además que, en muchos contextos, el color está asociado a ciertas características inherentes del sistema bajo estudio.

Tal es el caso de la infección por roya en hojas de café, la cual produce cambios de color en las hojas afectadas e incluso cada color indicando un nivel de afectación diferente.

2.6.2. RoCoLe: A robusta coffee leaf images dataset for evaluation of machine learning based methods in plant diseases recognition

En el artículo *RoCoLe: A robusta coffee leaf images dataset for evaluation of machine learning based methods in plant diseases recognition* [1], Jorge Parraga-Alava, Kevin Cusme, Angélica Loor y Esneider Santander nos proporcionan el dataset *RoCoLe: A robusta coffee leaf images dataset* [2] el cual contiene imágenes de hojas de café robusta manualmente clasificadas por su estado de salud y severidad de afectación por roya. Usaremos este dataset como la fuente de imágenes para nuestro proyecto y a su vez nos servirá como referencia para la verificación del desempeño de nuestro algoritmo.

RoCoLe contiene la información de 390 plantas de café robusta a las cuales se le tomaron 4 muestras de sus hojas haciendo un total de 1560 imágenes. Las muestras fueron tomadas en diferentes condiciones (iluminación, lado de la hoja) para proporcionar un conjunto más diverso de características.



Cada hoja presenta dos clasificaciones: la primera respecto a su estado de salud, ya sea saludable o no-saludable, y la segunda respecto al nivel de afectación por roya en caso de ser una hoja no-saludable. La Tabla 2.1 presenta la ponderación utilizada para la clasificación de los niveles de afectación.

Nivel	Categoría	Descripción	Área afectada
1	rust_level_1	Roya nivel 1	1 - 5 %
2	rust_level_2	Roya nivel 2	6 - 20 %
3	rust_level_3	Roya nivel 3	21 - 50 %
4	rust_level_4	Roya nivel 4	> 50 %

Tabla 2.1: Niveles de afectación por roya



3

PROCEDIMIENTO

A continuación se describen los procesos del algoritmo que permiten solucionar el problema especificado. El código fuente está disponible de manera digital en la plataforma de GitHub [3].

3.1. Lectura del dataset

Se comienza leyendo el dataset que contiene información que ha sido etiquetada de manera manual por los autores del mismo. Este proceso se describe en Código 1.

```
import json

annotations_file = "RoCoLe.json"

with open(annotations_file, "r") as f:
    annotations = json.load(f)
```

Código 1: Cargar las anotaciones del dataset



Utilizando la biblioteca `json` de Python leemos el archivo `RoCoLE.json` (originalmente `Annotations/RoCoLE-json.json`). La variable `annotations` contiene la información necesaria para construir nuestro conjunto de datos de prueba (véase Tabla 3.1).

Anotación	Descripción
ID	Identificador de la hoja
Label.Leaf.0.state	Estado de la hoja como saludable o infectada
Label.classification	Clasificación de la hoja o nivel de afectación
Label.Leaf.0.geometry	Puntos (x,y) que determinan el contorno de la hoja

Tabla 3.1: Anotaciones del dataset

3.1.1. La clase `CoffeeLeaf`

A continuación creamos una clase llamada `CoffeeLeaf` la cual se encarga de contener los datos proporcionados en las anotaciones y que representa a una hoja de café. Los atributos de esta clase pueden observarse en Código 2.

```
class CoffeeLeaf:
    def __init__(self, leaf_id, state, classification, image_bgr,
        ↪ geometry):
        self.id = leaf_id
        self.state_manual = state
        self.state_computed = None
        self.classification_manual = classification
        self.classification_computed = None
        self.image_bgr = image_bgr
        self.image_rgb = None
        self.roi_rgb = None
        self.roi_hsv = None
        self.masked_roi_rgb = None
        self.masked_roi_hue = None
        self.mask = None
        self.area = None
        self.affected_percentage = None
        self.histogram_hue = None
        self.limit_below = None
        self.limit_above = None
        self.binary = None
        self.contours = None
        self.contours_canvas = None
        self.polygon = None
        self.geometry = geometry
        self._processed = False
```

Código 2: La clase `CoffeeLeaf`



Una vez creada la clase `CoffeeLeaf` y leído los datos del dataset, procedemos a crear la lista `coffee_leaves` utilizando los datos de la Tabla 3.1, tal como se muestra en Código 3. El directorio `../rocole_photos/` contiene los archivos `.jpeg` del dataset (`Annotations/RoCoLe-voc.tar.gz/export`).

```
IMAGES_PATH = "../rocole_photos/"

coffee_leaves = []

for annotation in annotations:
    classification = annotation["Label"]["classification"]
    if classification != "red_spider_mite":
        leaf_id = annotation["ID"]
        state = annotation["Label"]["Leaf"][0]["state"]
        geometry = annotation["Label"]["Leaf"][0]["geometry"]
        leaf_image = f"{IMAGES_PATH}/{leaf_id}.jpeg"
        image_bgr = cv.imread(leaf_image)
        coffee_leaf = CoffeeLeaf(leaf_id, state, classification,
                                ↪ image_bgr, geometry)
        coffee_leaves.append(coffee_leaf)
```

Código 3: Lista de objetos `CoffeeLeaf`

3.2. Procesado de la imagen

Una vez creada la lista `coffee_leaves` iniciamos el procesamiento de las imágenes a través de la función `process` (Código 4) de la clase `CoffeeLeaf`. Véase Código 5.

```
def process(self):
    self._generate_image_rgb()
    self._create_polygon()
    self._create_roi()
    self._create_mask()
    self._create_masked_roi()
    self._compute_histogram()
    self._binarize()
    self._categorize()
    self._processed = True
```

Código 4: Función `process` de la clase `CoffeeLeaf`



```
for coffee_leaf in coffee_leaves:  
    coffee_leaf.process()
```

Código 5: Iniciar procesamiento de las imágenes

3.2.1. Conversión de BGR a RGB

Debido a que cuando creamos los objetos `CoffeeLeaf` el argumento `image_bgr` pasa datos de una imagen en color BGR (Blue, Green, Red), que es la representación de color por defecto de *OpenCV*, y ya que *matplotlib*, la herramienta para la visualización de las imágenes, utiliza una representación RGB (Red, Green, Blue), una conversión de color es necesaria. Véase Código 6.

```
def _generate_image_rgb(self):  
    self.image_rgb = cv.cvtColor(self.image_bgr, cv.COLOR_BGR2RGB)
```

Código 6: Convertir imagen BGR a RGB

El resultado de esta conversión permite visualizar la imagen original (Figura 3.1).



Figura 3.1: Imagen original en RGB

3.2.2. Creación de las regiones de interés

La anotación `geometry` del dataset nos provee de una serie de puntos (x,y) que representan el contorno de la hoja de café y que nos sirven para crear un polígono (Código 7).



```
def _create_polygon(self):  
    polygon_points = [list(point.values()) for point in self.geometry]  
    self.polygon = np.array(polygon_points)
```

Código 7: Puntos (x, y) del contorno de la hoja de café

El contorno de la hoja de café se puede apreciar en la Figura 3.2.



Figura 3.2: Polígono que delimita el contorno de la hoja

Posteriormente creamos el rectángulo mínimo que encierra a esta región, como se aprecia en la Figura 3.3 y lo usamos para recortar nuestra región de interés (véase Código 8).



Figura 3.3: Cuadro que aísla a la hoja de café

```
def _create_roi(self):  
    x,y,w,h = cv.boundingRect(self.polygon)  
    self.roi_rgb = self.image_rgb[y:y+h, x:x+w].copy()  
    self.roi_hsv = cv.cvtColor(self.roi_rgb, cv.COLOR_RGB2HSV)
```

Código 8: Crear regiones de interés

Creamos dos regiones de interés: la primera en RGB (Figura 3.4) para la presentación al usuario y la segunda en HSV (Hue, Saturation, Value) (Figura 3.5) que nos servirá en la segmentación de la imagen.



Figura 3.4: Región de interés en RGB




Figura 3.5: Región de interés en HSV

3.2.3. Creación de la máscara

Utilizando las regiones de interés previamente creadas y el polígono que delimita el contorno de la hoja, procedemos a crear una máscara (Código 9) que nos será útil en las operaciones matriciales del procesamiento de la imagen. Véase Figura 3.6.



```
def _create_mask(self):  
    self.mask = np.zeros(self.roi_hsv.shape[:2], np.uint8)  
    polygon_start = self.polygon.min(axis=0)  
    polygon_at_zero = self.polygon - polygon_start  
    CONTOURS = -1 # All contours  
    COLOR = (255, 255, 255) # White  
    THICKNESS = -1 # Fill  
    self.mask = cv.drawContours(self.mask, [polygon_at_zero], CONTOURS,  
    ↪ COLOR, THICKNESS)  
    self.area = cv.countNonZero(self.mask)
```

Código 9: Crear máscara




Figura 3.6: Máscara

Nótese que en Código 9 calculamos el área que ocupa la máscara (píxeles en color blanco), o lo que es lo mismo, el área de la hoja de café.

3.2.4. Enmascaramiento de las regiones de interés

Una vez teniendo la máscara y las regiones de interés, procedemos a *enmascarar* dichas regiones (Código 10). Para el caso de la región de interés en RGB es por mera conveniencia al presentar esta región al usuario. Sin embargo, para el enmascaramiento de la región de interés en HSV es de suma importancia usar únicamente el canal Hue (matiz) puesto que nuestra segmentación se basará en el color.

```
def _create_masked_roi(self):  
    self.masked_roi_rgb = cv.bitwise_and(self.roi_rgb, self.roi_rgb,  
    ↪ mask=self.mask)  
    self.masked_roi_hue = cv.bitwise_and(self.roi_hsv[:, :, 0], self.mask)
```

Código 10: Enmascarar las regiones de interés



El resultado de este enmascaramiento se puede apreciar en la Figura 3.7 para RGB y en la Figura 3.8 para Hue.



Figura 3.7: Región de interés RGB enmascarada




Figura 3.8: Región de interés Hue enmascarada

Nótese que el valor más bajo para el canal Hue no es un color negro sino un matiz rojo. Esto se debe a la representación circular que emplea el modelo HSV.

3.2.5. Histograma de la región de interés

Una vez que tenemos la región de interés en el canal Hue, procedemos a calcular su histograma (Código 11) utilizando la máscara (Figura 3.6) de tal manera que no representemos datos fuera del contorno de la hoja. El resultado de la distribución de color puede verse en la Figura 3.9.



```
def _compute_histogram(self):  
    hsv_normalizer = Normalize(vmin=0, vmax=179)  
    self.hsv_mappable = ScalarMappable(norm=hsv_normalizer, cmap='hsv')  
    self.histogram_hue = cv.calcHist([self.masked_roi_hue], [0],  
    ↪ self.mask, [180], [0,180])
```

Código 11: Calcular histograma de la región de interés




Figura 3.9: Histograma de la región de interés

3.2.6. Segmentación de la imagen

Del histograma nos interesa la región de la hoja que se considera saludable, es decir, la región del espectro Hue en matices verdes, un poco del amarillo-naranja (umbral inferior) y hasta la región azul (umbral superior) para cuando las hojas tengan un verde intenso acercándose a tonos azules.

En el Código 12 hemos asignado al umbral inferior el valor de 30 y al umbral superior el valor de 120. Segmentamos cada parte de los umbrales y el resultado los unimos usando una operación AND elemento por elemento, resultando en la imagen segmentada apropiadamente (Figura 3.10).



```
def _binarize(self):  
    GREEN_LIMIT_BELOW = 30  
    GREEN_LIMIT_ABOVE = 120  
    _, segments_below_green = cv.threshold(self.masked_roi_hue,  
    ↪ GREEN_LIMIT_BELOW, 179, cv.THRESH_BINARY)  
    _, segments_above_green = cv.threshold(self.masked_roi_hue,  
    ↪ GREEN_LIMIT_ABOVE, 179, cv.THRESH_BINARY_INV)  
    self.binary = cv.bitwise_and(segments_below_green,  
    ↪ segments_above_green)
```

Código 12: Segmentar la región de interés




Figura 3.10: Imagen segmentada

3.2.7. Clasificación de la hoja

Una vez segmentada la hoja de café en su parte saludable (píxeles blancos) e infectada (píxeles negros dentro de la máscara), procedemos a clasificarla utilizando la misma ponderación usada por los autores (Tabla 2.1).

Para el cálculo del porcentaje afectado, simplemente calculamos el área saludable de la hoja a partir de la imagen segmentada (Figura 3.10) y restamos este valor al área de la máscara (Código 9), como se describe en Código 13.



```
def _categorize(self):
    healthy_area = cv.countNonZero(self.binary)
    affected_area = self.area - healthy_area
    self.affected_percentage = int((affected_area / self.area) * 100)
    if self.affected_percentage < 1:
        self.state_computed = "healthy"
        self.classification_computed = "healthy"
    elif self.affected_percentage < 6:
        self.state_computed = "unhealthy"
        self.classification_computed = "rust_level_1"
    elif self.affected_percentage < 21:
        self.state_computed = "unhealthy"
        self.classification_computed = "rust_level_2"
    elif self.affected_percentage < 51:
        self.state_computed = "unhealthy"
        self.classification_computed = "rust_level_3"
    else:
        self.state_computed = "unhealthy"
        self.classification_computed = "rust_level_4"
```

Código 13: Clasificar hoja de café

Este proceso marca el fin del algoritmo para el procesamiento de la imagen, obteniéndose dos clasificaciones: 1) el estado de la hoja y 2) el nivel de afectación en caso de ser una hoja infectada.

3.3. Presentación de los datos

A continuación se muestran las funciones que permiten describir el objeto **Coffee Leaf** de una manera intuitiva al usuario. La función **describe** (Código 14) orquesta la presentación pero cada función puede accederse de manera individual.

```
def describe(self):
    if not self._processed:
        print("Imagen aún no procesada")
        return
    self.show_summary()
    self.show_original_image()
    self.show_mask()
    self.show_roi()
    self.show_roi(hue=True)
    self.show_binary()
    self.show_histogram()
```

Código 14: Describir objeto CoffeeLeaf



3.3.1. Resumen

La función `show_summary` (Código 15) muestra la clasificación original de la hoja, la nueva clasificación calculada y el porcentaje de afectación calculado.

```
def show_summary(self):
    original_class = self.classification_manual
    new_class = self.classification_computed
    affected_area = self.affected_percentage
    title_md =
    ↪ f"### {original_class} --> {new_class} ({affected_area} %)"
    display(Markdown(title_md))
```

Código 15: Mostrar resumen de la clasificación

3.3.2. Imagen original

La función `show_original_image` (Código 16) muestra la imagen original en RGB (Figura 3.1) y agrega un título.

```
def show_original_image(self):
    plt.imshow(self.image_rgb)
    plt.title("Imagen Original")
    plt.axis("off")
    plt.show()
```

Código 16: Mostrar imagen original

3.3.3. Máscara

La función `show_mask` (Código 17) muestra la máscara calculada (Figura 3.6) y agrega un título. Nótese que es necesario especificar un mapa de colores, en este caso *gray*, para poder visualizar la máscara en escala de grises, ya que *matplotlib* utiliza el mapa de colores *viridis* por defecto.

```
def show_mask(self):
    plt.imshow(self.mask, cmap="gray")
    plt.title("Máscara")
    plt.axis("off")
    plt.show()
```

Código 17: Mostrar máscara



3.3.4. Regiones de interés

La función `show_roi` (Código 18) se encarga de mostrar las regiones de interés enmascaradas y agrega un título. Esta función recibe un argumento *booleano* `hue` para indicar si se debe mostrar la región de interés en RGB (Figura 3.7) o bien la del canal Hue (Figura 3.8). Nótese que si se quiere mostrar la región de interés del canal Hue, es necesario especificar el mapa de colores *hsv* para una visualización apropiada.

```
def show_roi(self, hue=False):
    if hue:
        colorspace = "Hue"
        plt.imshow(self.masked_roi_hue, cmap="hsv")
    else:
        colorspace = "RGB"
        plt.imshow(self.masked_roi_rgb)
    plt.title(f"Región de Interés ({colorspace})")
    plt.axis("off")
    plt.show()
```

Código 18: Mostrar regiones de interés

3.3.5. Imagen segmentada

La función `show_binary` (Código 19) se encarga de mostrar la imagen segmentada (Figura 3.10) y agrega un título.

```
def show_binary(self):
    plt.imshow(self.binary, cmap="gray")
    plt.title(f"Segmentación")
    plt.axis("off")
    plt.show()
```

Código 19: Mostrar segmentación de la imagen

3.3.6. Histograma

Finalmente, la función `show_histogram` (Código 20) se encarga de mostrar el histograma (Figura 3.9) de la región de interés del canal Hue (Figura 3.8) y agrega un título, el cual contiene el valor Hue (matiz) más abundante.



```
def show_histogram(self):
    fig, ax = plt.subplots()
    ax.plot(self.histogram_hue)
    colorbar = plt.colorbar(self.hsv_mappable, ax=ax, location="bottom")
    colorbar.set_ticks([])
    idx_max = np.argmax(self.histogram_hue)
    plt.title(f"Histograma (Hue) Máx={idx_max}")
    plt.margins(x=0)
    plt.show()
```

Código 20: Mostrar histograma de la región de interés



4

RESULTADOS

En el capítulo anterior describimos el proceso para segmentar las imágenes a través del canal Hue. Empleando diferentes valores para los parámetros de umbral inferior y umbral superior (Sección 3.2.6) se obtienen los siguientes resultados.

4.1. Segmentación Hue en 40 y 120

Clasificación	Total	Aciertos	Errores	Eficiencia
Estado	1393	694	699	49.820
Categoría	1393	287	1106	20.603

Tabla 4.1: Eficiencias generales con Hue 40-120




Figura 4.1: Eficiencia detectando el estado con Hue 40-120




Figura 4.2: Eficiencia detectando la categoría con Hue 40-120

Categoría	Original	Calculado	Eficiencia
healthy	791	100	12.642
rust_level_1	344	89	25.872
rust_level_2	166	69	41.566
rust_level_3	62	17	27.419
rust_level_4	30	12	40.0

Tabla 4.2: Eficiencia por categoría con Hue 40-120




Figura 4.3: Eficiencia por categoría con Hue 40-120

4.2. Segmentación Hue en 40 y 80

Clasificación	Total	Aciertos	Errores	Eficiencia
Estado	1393	670	723	48.097
Categoría	1393	259	1134	18.592

Tabla 4.3: Eficiencias generales con Hue 40-80




Figura 4.4: Eficiencia detectando el estado con Hue 40-80




Figura 4.5: Eficiencia detectando la categoría con Hue 40-80

Categoría	Original	Calculado	Eficiencia
healthy	791	75	9.481
rust_level_1	344	77	22.383
rust_level_2	166	73	43.975
rust_level_3	62	22	35.483
rust_level_4	30	12	40.0

Tabla 4.4: Eficiencia por categoría con Hue 40-80




Figura 4.6: Eficiencia por categoría con Hue 40-80



4.3. Segmentación Hue en 30 y 120

Clasificación	Total	Aciertos	Errores	Eficiencia
Estado	1393	962	431	69.059
Categoría	1393	715	678	51.328

Tabla 4.5: Eficiencias generales con Hue 30-120




Figura 4.7: Eficiencia detectando el estado con Hue 30-120




Figura 4.8: Eficiencia detectando la categoría con Hue 30-120



4.4. SEGMENTACIÓN HUE EN 30 Y 100

Categoría	Original	Calculado	Eficiencia
healthy	791	445	56.257
rust_level_1	344	196	56.976
rust_level_2	166	67	40.361
rust_level_3	62	6	9.677
rust_level_4	30	1	3.333

Tabla 4.6: Eficiencia por categoría con Hue 30-120




Figura 4.9: Eficiencia por categoría con Hue 30-120

4.4. Segmentación Hue en 30 y 100

Clasificación	Total	Aciertos	Errores	Eficiencia
Estado	1393	961	432	68.987
Categoría	1393	714	679	51.256

Tabla 4.7: Eficiencias generales con Hue 30-100




Figura 4.10: Eficiencia detectando el estado con Hue 30-100




Figura 4.11: Eficiencia detectando la categoría con Hue 30-100

Categoría	Original	Calculado	Eficiencia
healthy	791	436	55.120
rust_level_1	344	202	58.720
rust_level_2	166	69	41.566
rust_level_3	62	6	9.677
rust_level_4	30	1	3.333

Tabla 4.8: Eficiencia por categoría con Hue 30-100




Figura 4.12: Eficiencia por categoría con Hue 30-100

4.5. Segmentación Hue en 30 y 80

Clasificación	Total	Aciertos	Errores	Eficiencia
Estado	1393	939	454	67.408
Categoría	1393	684	709	49.102

Tabla 4.9: Eficiencias generales con Hue 30-80




Figura 4.13: Eficiencia detectando el estado con Hue 30-80




Figura 4.14: Eficiencia detectando la categoría con Hue 30-80

Categoría	Original	Calculado	Eficiencia
healthy	791	402	50.821
rust_level_1	344	199	57.848
rust_level_2	166	74	44.578
rust_level_3	62	8	12.903
rust_level_4	30	1	3.333

Tabla 4.10: Eficiencia por categoría con Hue 30-80




Figura 4.15: Eficiencia por categoría con Hue 30-80



4.6. Segmentación Hue en 28 y 120

Clasificación	Total	Aciertos	Errores	Eficiencia
Estado	1393	993	400	71.284
Categoría	1393	755	638	54.199

Tabla 4.11: Eficiencias generales con Hue 28-120




Figura 4.16: Eficiencia detectando el estado con Hue 28-120




Figura 4.17: Eficiencia detectando la categoría con Hue 28-120



Categoría	Original	Calculado	Eficiencia
healthy	791	511	64.601
rust_level_1	344	188	54.651
rust_level_2	166	53	31.927
rust_level_3	62	2	3.225
rust_level_4	30	1	3.333

Tabla 4.12: Eficiencia por categoría con Hue 28-120




Figura 4.18: Eficiencia por categoría con Hue 28-120

4.7. Segmentación Hue en 25 y 120

Clasificación	Total	Aciertos	Errores	Eficiencia
Estado	1393	988	405	70.926
Categoría	1393	770	623	55.276

Tabla 4.13: Eficiencias generales con Hue 25-120



4.7. SEGMENTACIÓN HUE EN 25 Y 120




Figura 4.19: Eficiencia detectando el estado con Hue 25-120




Figura 4.20: Eficiencia detectando la categoría con Hue 25-120

Categoría	Original	Calculado	Eficiencia
healthy	791	563	71.175
rust_level_1	344	175	50.872
rust_level_2	166	31	18.674
rust_level_3	62	0	0.0
rust_level_4	30	1	3.333

Tabla 4.14: Eficiencia por categoría con Hue 25-120




Figura 4.21: Eficiencia por categoría con Hue 25-120



5

CONCLUSIONES

En este capítulo se presenta el análisis de los resultados obtenidos, las limitaciones encontradas y algunas consideraciones y mejoras para trabajos futuros.

5.1. Conclusiones específicas

5.1.1. Unicidad de la solución

El algoritmo no provee una solución general, es decir, dependiendo de la clasificación de las hojas que se desea buscar o analizar, debería elegirse umbrales de segmentación diferentes. La Tabla 5.1 proporciona la mejor configuración encontrada para cada una de las categorías establecidas.



Clasificación	Umbral de segmentación	Eficiencia %
healthy	25 - 120	71.175
rust_level_1	30 - 100	58.72
rust_level_2	30 - 80	44.578
rust_level_3	40 - 80	35.483
rust_level_4	40 - 80/120	40.00

Tabla 5.1: Umbrales de segmentación recomendados

5.1.2. Inconsistencias en el dataset

Parte de la ineficiencia del algoritmo se debe a que algunas anotaciones en el dataset fueron mal etiquetadas: no puede suceder que la categoría de una hoja sea marcada como saludable mientras que su estado sea no-saludable (Figura 5.1). Se encontraron 4 inconsistencias en el dataset (descartando la categoría *araña roja*).

```
for coffee_leaf in coffee_leaves_state_incorrect[0:20]:  
    print(coffee_leaf.state_manual, coffee_leaf.state_computed)  
    print(coffee_leaf.classification_manual, coffee_leaf.classification_computed)  
    coffee_leaf.describe()
```

```
unhealthy healthy  
healthy healthy
```

healthy --> healthy (0 %)

Figura 5.1: Inconsistencias en el dataset

5.2. Casos especiales

Existen algunos casos para los cuales el algoritmo no proporciona un rendimiento adecuado, los cuales se describen a continuación.

5.2.1. Iluminación excesiva

Una iluminación excesiva (Figura 5.2) puede crear matices falsos en el canal Hue (Figura 5.3) lo cual provocará una segmentación incorrecta de la imagen (Figura 5.4).



Figura 5.2: Iluminación excesiva en una hoja




Figura 5.3: Matices falsos por iluminación excesiva



Figura 5.4: Segmentación de una hoja con iluminación excesiva



5.2.2. Iluminación artificial o no contemplada

De igual manera, una iluminación creada por una fuente artificial (una lámpara) o no contemplada (día nublado), puede causar un despliegue de la imagen inconsistente o contraintuitivo (Figura 5.6).




Figura 5.5: Hoja con iluminación no contemplada




Figura 5.6: Despliegue contraintuitivo de una imagen

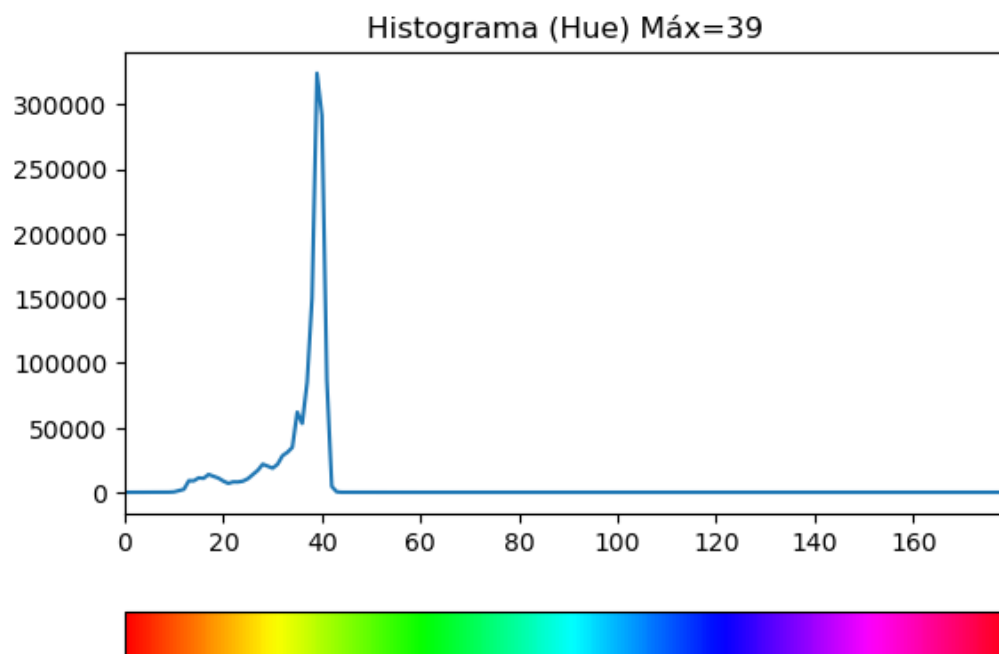


Figura 5.7: Histograma de una imagen con despliegue contraintuitivo

5.2.3. Envés de la hoja

El algoritmo ignora el haz y el envés (Figura 5.8) de la hoja, por lo tanto, aplica el mismo proceso en ambas condiciones. Sin embargo, los nervios de la hoja presentan generalmente un matiz diferente al resto de la hoja (Figura 5.9), provocando que la segmentación sea errónea (Figura 5.10).



Figura 5.8: Envés de una hoja saludable




Figura 5.9: Canal Hue del envés de una hoja saludable



Figura 5.10: Segmentación del envés de una hoja saludable

5.3. Mejoras y trabajo a futuro

5.3.1. Detección de objetos

Actualmente el algoritmo se apoya en las anotaciones del dataset para la determinación del contorno de las hojas y la creación de la máscara. Sin embargo, el aislamiento no es preciso e introduce ruido al sistema.

La Figura 5.11 muestra el contorno asignado a una hoja saludable el cual no es preciso e introduce matices no deseados en el canal Hue (Figura 5.12) provocando una segmentación incorrecta de la imagen (Figura 5.13).

Una mejora sugerida para resolver este problema es la creación de un algoritmo (o método) para la detección de objetos que permita aislar la región de interés de manera precisa mejorando el rendimiento global del algoritmo.



Figura 5.11: Contorno impreciso de una hoja saludable




Figura 5.12: Matices no deseados en un contorno impreciso



Figura 5.13: Introducción de zonas afectadas debido a un contorno impreciso



5.3.2. Análisis en RGB

A pesar de que la segmentación por matices en el canal Hue es útil para la detección de zonas afectadas, no nos proporciona información acerca de la severidad en la zona, o si bien lo hace, tal información es fácil de confundirse con otras propiedades que generan matices similares (Figura 5.15).

Existen casos en que una hoja presenta un área mínima de afectación pero con una severidad muy alta (Figura 5.14) catalogándola automáticamente como severamente afectada. En otras palabras, el área afectada (Figura 5.16) no es suficiente para la clasificación correcta de la hoja.

Una segmentación basada en colores RGB podría ser más eficaz e intuitiva para estos casos.



Figura 5.14: Hoja de café con afectación severa en zona reducida




Figura 5.15: Canal Hue de afectación severa en zona reducida



Figura 5.16: Área afectada de una hoja con afectación severa en zona reducida

5.3.3. Optimización de los umbrales de segmentación

Los umbrales de segmentación sugeridos en la Tabla 5.1 fueron calculados manualmente a través de un enfoque de prueba y error. Por lo tanto, pueden existir umbrales que mejoran el rendimiento del algoritmo.

Una forma automatizada de encontrar umbrales más eficientes, o de verificar que no los hay, es mediante el uso de algoritmos genéticos. Este proceso identificaría la configuración más eficiente de los umbrales maximizando su nivel de eficiencia, o bien, reduciendo el margen de error.

5.3.4. Redes neuronales artificiales

Los resultados de este proyecto se obtuvieron a partir de un enfoque tradicional de procesamiento digital de imágenes el cual involucra métodos más simples de entender y manipular pero que no son tan eficientes en problemas generales.

En contraste, un enfoque basado en el uso de redes neuronales artificiales y técnicas de *deep learning* o *machine learning* para el análisis de imágenes podría producir mejores resultados.

5.4. Conclusiones generales

Un procesamiento digital de imágenes tradicional generalmente es más eficiente cuando el campo u objeto de estudio es reducido y está normalizado, es decir, no hay mucha variabilidad en las condiciones que describen al sistema.

Este tipo de procesamiento nos da la flexibilidad de poder controlar las características a analizar o identificar de manera precisa, sin embargo, es eso mismo lo que lo hace menos portable o escalable ya que para nuevas condiciones en el sistema, el algoritmo deberá ser ajustado, implicando un alto grado de supervisión humana.

Cabe mencionar que podemos mejorar estos algoritmos tanto como sea necesario para hacerlos más precisos y aumentar su eficiencia pero hay que considerar el tiempo de desarrollo y el costo computacional agregado.

REFERENCIAS

- [1] J. Parraga-Alava, K. Cusme, A. Loor, and E. Santander, “Rocole: A robusta coffee leaf images dataset for evaluation of machine learning based methods in plant diseases recognition,” *Data in Brief*, vol. 25, p. 104414, 2019. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S2352340919307693>
- [2] J. Parraga, K. Cusme, A. Loor, and E. Santander, “Rocole: A robusta coffee leaf images dataset,” Mendeley Data, V2, doi: 10.17632/c5yvn32dzg.2, 05 2019. [Online]. Available: <https://data.mendeley.com/datasets/c5yvn32dzg/2>
- [3] L. Dominguez, “Coffee Leaves Classification,” 07 2025. [Online]. Available: <https://github.com/LindermanDgz/coffee-leaves-classification>

