

Índice general

1. Introducción	6
1.1. Procesamiento digital de imágenes	6
2. Planteamiento del problema	7
2.1. Objetivo general	7
2.2. Objetivo específico	7
2.3. Alcance	7
2.4. Justificación	7
2.5. Especificaciones técnicas	7
3. Procedimiento	9
3.1. Lectura del dataset	9
3.1.1. La clase CoffeeLeaf	10
3.2. Procesado de la imagen	10
3.2.1. Conversión de BGR a RGB	11
3.2.2. Creación de las regiones de interés	12
3.2.3. Creación de la máscara	14
3.2.4. Enmascaramiento de las regiones de interés	15
3.2.5. Histograma de la región de interés	16
3.2.6. Segmentación de la imagen	17
3.2.7. Clasificación de la hoja	18
3.3. Presentación de los datos	19
3.3.1. Resumen	19
3.3.2. Imagen original	19
3.3.3. Máscara	19
3.3.4. Regiones de interés	20
3.3.5. Imagen segmentada	20
3.3.6. Histograma	20
4. Resultados	22
4.1. Casos especiales	22
4.1.1. Iluminación	22
4.1.2. Envés de la hoja	22

5. Conclusiones	23
5.1. Conclusiones específicas	23
5.2. Conclusiones generales	23
Referencias	23

Índice de códigos

1.	Cargar las anotaciones del dataset	9
2.	La clase CoffeeLeaf	10
3.	Lista de objetos CoffeLeaf	11
4.	Función process del la clase CoffeeLeaf	11
5.	Iniciar procesamiento de las imágenes	11
6.	Convertir imagen BGR a RGB	12
7.	Puntos (x, y) del contorno de la hoja de café	12
8.	Crear regiones de interés	14
9.	Crear máscara	15
10.	Enmascarar las regiones de interés	15
11.	Cálcular histograma de la región de interés	17
12.	Segmentar la región de interés	18
13.	Clasificar hoja de café	19
14.	Mostrar resumen de la clasificación	19
15.	Mostrar imagen original	20
16.	Mostrar máscara	20
17.	Mostrar regiones de interés	20
18.	Mostrar segmentación de la imagen	21
19.	Mostrar histograma de la región de interés	21

Índice de figuras

3.1. Imagen original en RGB	12
3.2. Polígono que delimita el contorno de la hoja	13
3.3. Cuadro que aísla a la hoja de café	13
3.4. Región de interés en RGB	14
3.5. Región de interés en HSV	14
3.6. Máscara	15
3.7. Región de interés RGB enmascarada	16
3.8. Región de interés Hue enmascarada	16
3.9. Histograma de la región de interés	17
3.10. Imagen segmentada	18

Índice de tablas

3.1. Anotaciones del dataset	9
--	---

Capítulo 1

Introducción

1.1. Procesamiento digital de imágenes

Capítulo 2

Planteamiento del problema

2.1. Objetivo general

Demostrar las habilidades adquiridas durante el seminario *Procesamiento Digital de Imágenes: Fundamentos y Aplicaciones con GNU Octave y Open CV* aplicando los principios y técnicas básicas de manera práctica a un proyecto en particular.

2.2. Objetivo específico

Crear un algoritmo que clasifique hojas de café como sanas o infectadas y su nivel de afectación, y evaluar su eficiencia comparando los resultados obtenidos con los proporcionados en el conjunto de datos.

2.3. Alcance

A pesar de que el conjunto de datos de prueba contiene seis clasificaciones para las hojas, el algoritmo desarrollado sólo incluirá la clasificación sana y los cuatro niveles de afectación, excluyendo la clasificación *araña roja* debido a las restricciones en el tiempo del proyecto.

2.4. Justificación

El algoritmo y las técnicas utilizadas pueden aplicarse de manera directa en el mundo real dentro del área de la agricultura y/o agronomía, e idealmente puede servir como base para desarrollar procesos automatizados para el control de calidad en el campo del café.

2.5. Especificaciones técnicas

Se utilizará Python como lenguaje de programación para la implementación del algoritmo debido a su facilidad de uso y al amplio número de bibliotecas disponibles para el

procesamiento de imágenes tales como OpenCV.

Capítulo 3

Procedimiento

A continuación se describen los procesos del algoritmo que permiten solucionar el problema especificado. El código fuente está disponible de manera digital en la plataforma de GitHub [1].

3.1. Lectura del dataset

Se comienza leyendo el dataset que contiene información que ha sido etiquetada de manera manual por los autores del mismo. Este proceso se describe en Código 1.

```
import json

annotations_file = "RoCoLe.json"

with open(annotations_file, "r") as f:
    annotations = json.load(f)
```

Código 1: Cargar las anotaciones del dataset

Utilizando la biblioteca `json` de Python leemos el archivo `RoCoLe.json` (originalmente `Annotations/RoCoLe-json.json`). La variable `annotations` contiene la información necesaria para contruir nuestro conjunto de datos de prueba (véase Tabla 3.1).

Anotación	Descripción
ID	Identificador de la hoja
Label.Leaf.0.state	Estado de la hoja como saludable o infectada
Label.classification	Clasificación de la hoja o nivel de afectación
Label.Leaf.0.geometry	Puntos (x,y) que determinan el contorno de la hoja

Tabla 3.1: Anotaciones del dataset

3.1.1. La clase CoffeeLeaf

A continuación creamos una clase llamada `CoffeeLeaf` la cual se encarga de contener los datos proporcionados en las anotaciones y que representa a una hoja de café. Los atributos de esta clase pueden observarse en Código 2.

```
class CoffeeLeaf:
    def __init__(self, leaf_id, state, classification, image_bgr, geometry):
        self.id = leaf_id
        self.state_manual = state
        self.state_computed = None
        self.classification_manual = classification
        self.classification_computed = None
        self.image_bgr = image_bgr
        self.image_rgb = None
        self.roi_rgb = None
        self.roi_hsv = None
        self.masked_roi_rgb = None
        self.masked_roi_hue = None
        self.mask = None
        self.area = None
        self.affected_percentage = None
        self.histogram_hue = None
        self.limit_below = None
        self.limit_above = None
        self.binary = None
        self.contours = None
        self.contours_canvas = None
        self.polygon = None
        self.geometry = geometry
        self._processed = False
```

Código 2: La clase CoffeeLeaf

Una vez creada la clase `CoffeeLeaf` y leído los datos del dataset, procedemos a crear la lista `coffee_leaves` utilizando los datos de la Tabla 3.1, tal como se muestra en Código 3. El directorio `../rocole_photos/` contiene los archivos `.jpeg` del dataset (`Annotations/RoCoLe-voc.tar.gz/export`).

3.2. Procesado de la imagen

Una vez creada la lista `coffee_leaves` iniciamos el procesamiento de las imágenes a través de la función `process` (Código 4) de la clase `CoffeeLeaf`. Véase Código 5.

```

IMAGES_PATH = "../rocole_photos/"

coffee_leaves = []

for annotation in annotations:
    classification = annotation["Label"]["classification"]
    if classification != "red_spider_mite":
        leaf_id = annotation["ID"]
        state = annotation["Label"]["Leaf"][0]["state"]
        geometry = annotation["Label"]["Leaf"][0]["geometry"]
        leaf_image = f"{IMAGES_PATH}/{leaf_id}.jpeg"
        image_bgr = cv.imread(leaf_image)
        coffee_leaf = CoffeeLeaf(leaf_id, state,
                                classification, image_bgr, geometry)
        coffee_leaves.append(coffee_leaf)

```

Código 3: Lista de objetos CoffeLeaf

```

def process(self):
    self._generate_image_rgb()
    self._create_polygon()
    self._create_roi()
    self._create_mask()
    self._create_masked_roi()
    self._compute_histogram()
    self._binarize()
    self._categorize()
    self._processed = True

```

Código 4: Función process del la clase CoffeeLeaf

```

for coffee_leaf in coffee_leaves:
    coffee_leaf.process()

```

Código 5: Iniciar procesamiento de las imágenes

3.2.1. Conversión de BGR a RGB

Debido a que cuando creamos los objetos `CoffeeLeaf` el argumento `image_bgr` pasa datos de una imagen en color BGR (Blue, Green, Red), que es la representación de color por defecto de *OpenCV*, y ya que *matplotlib*, la herramienta para la visualización de las imágenes, utiliza una representación RGB (Red, Green, Blue), una conversión de color es necesaria. Véase Código 6.

```
def _generate_image_rgb(self):  
    self.image_rgb = cv.cvtColor(self.image_bgr, cv.COLOR_BGR2RGB)
```

Código 6: Convertir imagen BGR a RGB

El resultado de esta conversión permite visualizar la imagen original (Figura 3.1).



Figura 3.1: Imagen original en RGB

3.2.2. Creación de las regiones de interés

La anotación `geometry` del dataset nos provee de una serie de puntos (x,y) que representan el contorno de la hoja de café y que nos sirven para crear un polígono (Código 7).

```
def _create_polygon(self):  
    polygon_points = [list(point.values()) for point in self.geometry]  
    self.polygon = np.array(polygon_points)
```

Código 7: Puntos (x, y) del contorno de la hoja de café

El contorno de la hoja de café se puede apreciar en la Figura 3.2.

Posteriormente creamos el rectángulo mínimo que encierra a esta región, como se aprecia en la Figura 3.3 y lo usamos para recortar nuestra región de interés (véase Código 8).



Figura 3.2: Polígono que delimita el contorno de la hoja



Figura 3.3: Cuadro que aísla a la hoja de café

Creamos dos regiones de interés: la primera en RGB (Figura 3.4) para la presentación al usuario y la segunda en HSV (Hue, Saturation, Value) (Figura 3.5) que nos servirá en la segmentación de la imagen.

```
def _create_roi(self):
    x,y,w,h = cv.boundingRect(self.polygon)
    self.roi_rgb = self.image_rgb[y:y+h, x:x+w].copy()
    self.roi_hsv = cv.cvtColor(self.roi_rgb, cv.COLOR_RGB2HSV)
```

Código 8: Crear regiones de interés



Figura 3.4: Región de interés en RGB




Figura 3.5: Región de interés en HSV

3.2.3. Creación de la máscara

Utilizando las regiones de interés previamente creadas y el polígono que delimita el contorno de la hoja, procedemos a crear una máscara (Código 9) que nos será útil en las operaciones matriciales del procesamiento de la imagen. Véase Figura 3.6.

Nótese que en Código 9 calculamos el área que ocupa la máscara (píxeles en color blanco), o lo que es mismo, el área de la hoja de café.


```
def _create_mask(self):
    self.mask = np.zeros(self.roi_hsv.shape[:2], np.uint8)
    polygon_start = self.polygon.min(axis=0)
    polygon_at_zero = self.polygon - polygon_start
    CONTOURS = -1 # All contours
    COLOR = (255, 255, 255) # White
    THICKNESS = -1 # Fill
    self.mask = cv.drawContours(
        self.mask, [polygon_at_zero], CONTOURS, COLOR, THICKNESS
    )
    self.area = cv.countNonZero(self.mask)
```

Código 9: Crear máscara




Figura 3.6: Máscara

3.2.4. Enmascaramiento de las regiones de interés

Una vez teniendo la máscara y las regiones de interés, procedemos a *enmascarar* dichas regiones (Código 10). Para el caso de la región de interés en RGB es por mera conveniencia al presentar esta región al usuario. Sin embargo, para el enmascaramiento de la region de interés en HSV es de suma importancia usar únicamente el canal Hue (Matiz) puesto que nuestra segmantación se basará en el color.

```
def _create_masked_roi(self):
    self.masked_roi_rgb = cv.bitwise_and(self.roi_rgb,
                                          self.roi_rgb, mask=self.mask)
    self.masked_roi_hue = cv.bitwise_and(self.roi_hsv[:, :, 0], self.mask)
```

Código 10: Enmascarar las regiones de interés

El resultado de este enmascaramiento se puede apreciar en la Figura 3.7 prara RGB y en la Figura 3.8 para Hue.



Figura 3.7: Región de interés RGB enmascarada




Figura 3.8: Región de interés Hue enmascarada

Nótese que el valor más bajo para el canal Hue no es un color negro sino un matiz rojo. Esto se debe a la representación circular que emplea el modelo HSV.

3.2.5. Histograma de la región de interés

Una vez que tenemos la región de interés en el canal Hue, procedemos a calcular su histograma (Código 11) utilizando la máscara (Figura 3.6) de tal manera que no representemos datos fuera del contorno de la hoja. El resultado de la distribución de color puede verse en la Figura 3.9.


```
def _compute_histogram(self):
    hsv_normalizer = Normalize(vmin=0, vmax=179)
    self.hsv_mappable = ScalarMappable(norm=hsv_normalizer, cmap='hsv')
    self.histogram_hue = cv.calcHist([self.masked_roi_hue],
                                     [0], self.mask, [180], [0,180])
```

Código 11: Calcular histograma de la región de interés




Figura 3.9: Histograma de la región de interés

3.2.6. Segmentación de la imagen

Del histograma nos interesa la región de la hoja que se considera saludable, es decir, la región del espectro Hue en matices verdes, un poco del amarillo-naranja (umbral inferior) y hasta la región azul (umbral superior) para cuando las hojas tengan un verde intenso acercándose a tonos azules.

En el Código 12 hemos asignado al umbral inferior el valor de 30 y al umbral superior el valor de 120. Segmentamos cada parte de los umbrales y el resultado los unimos usando una operación AND elemento por elemento, resultando en la imagen segmentada apropiadamente (Figura 3.10).

```

def _binarize(self):
    GREEN_LIMIT_BELOW = 30
    GREEN_LIMIT_ABOVE = 120
    _, segments_below_green = cv.threshold(self.masked_roi_hue,
                                           GREEN_LIMIT_BELOW,
                                           179,
                                           cv.THRESH_BINARY)
    _, segments_above_green = cv.threshold(self.masked_roi_hue,
                                           GREEN_LIMIT_ABOVE,
                                           179,
                                           cv.THRESH_BINARY_INV)
    self.binary = cv.bitwise_and(segments_below_green,
                                 segments_above_green)

```

Código 12: Segmentar la región de interés



Figura 3.10: Imagen segmentada

3.2.7. Clasificación de la hoja

Una vez segmentada la hoja de café en su parte saludable (píxeles blancos) e infectada (píxeles negros dentro de la máscara), procedemos a clasificarla utilizando la misma ponderación usada por los autores (REF Tabla).

Para el cálculo del porcentaje afectado, simplemente calculamos el área saludable de la hoja a partir de la imagen segmentada (Figura 3.10) y restamos este valor al área de la máscara (Código 9), como se describe en Código 13.

Esta clasificación marca el fin del algoritmo para el procesamiento de la imagen, obteniéndose dos categorías: 1) el estado de la hoja y 2) el nivel de afectación en caso de ser una hoja infectada.

```

def _categorize(self):
    healthy_area = cv.countNonZero(self.binary)
    affected_area = self.area - healthy_area
    self.affected_percentage = int((affected_area / self.area) * 100)
    if self.affected_percentage < 1:
        self.state_computed = "healthy"
        self.classification_computed = "healthy"
    elif self.affected_percentage < 6:
        self.state_computed = "unhealthy"
        self.classification_computed = "rust_level_1"
    elif self.affected_percentage < 21:
        self.state_computed = "unhealthy"
        self.classification_computed = "rust_level_2"
    elif self.affected_percentage < 51:
        self.state_computed = "unhealthy"
        self.classification_computed = "rust_level_3"
    else:
        self.state_computed = "unhealthy"
        self.classification_computed = "rust_level_4"

```

Código 13: Clasificar hoja de café

3.3. Presentación de los datos

3.3.1. Resumen

```

def show_summary(self):
    original_class = self.classification_manual
    new_class = self.classification_computed
    title_md = f"### {original_class} --> " \
               "{new_class} ({self.affected_percentage} %)"
    display(Markdown(title_md))

```

Código 14: Mostrar resumen de la clasificación

3.3.2. Imagen original

3.3.3. Máscara

```
def show_original_image(self):
    plt.imshow(self.image_rgb)
    plt.title("Imagen Original")
    plt.axis("off")
    plt.show()
```

Código 15: Mostrar imagen original

```
def show_mask(self):
    plt.imshow(self.mask, cmap="gray")
    plt.title("Máscara")
    plt.axis("off")
    plt.show()
```

Código 16: Mostrar máscara

3.3.4. Regiones de interés

```
def show_roi(self, hue=False):
    if hue:
        colorspace = "Hue"
        plt.imshow(self.masked_roi_hue, cmap="hsv")
    else:
        colorspace = "RGB"
        plt.imshow(self.masked_roi_rgb)
    plt.title(f"Región de Interés ({colorspace})")
    plt.axis("off")
    plt.show()
```

Código 17: Mostrar regiones de interés

3.3.5. Imagen segmentada

3.3.6. Histograma

```
def show_binary(self):
    plt.imshow(self.binary, cmap="gray")
    plt.title(f"Segmentación")
    plt.axis("off")
    plt.show()
```

Código 18: Mostrar segmentación de la imagen

```
def show_histogram(self):
    fig, ax = plt.subplots()
    ax.plot(self.histogram_hue)
    colorbar = plt.colorbar(self.hsv_mappable, ax=ax, location="bottom")
    colorbar.set_ticks([])
    idx_max = np.argmax(self.histogram_hue)
    plt.title(f"Histograma (Hue) Máx={idx_max}")
    plt.margins(x=0)
    plt.show()
```

Código 19: Mostrar histograma de la región de interés

Capítulo 4

Resultados

4.1. Casos especiales

4.1.1. Iluminación

4.1.2. Envés de la hoja

Capítulo 5

Conclusiones

5.1. Conclusiones específicas

5.2. Conclusiones generales

Referencias

- [1] L. Dominguez, “Coffee Leaves Classification,” 07 2025. [Online]. Available: <https://github.com/LindermanDgz/coffee-leaves-classification>